Lab4 矩阵乘法器（自选）

【该实验与张展鹏同学共同完成】

一、实验目标

1、使用 Vitis HLS 构建一个项目
2、在 Vitis HLS 中生成矩阵乘法加速的 IP 核，进行仿真、综合与 IP 导出。
3、使用 Vivado 对 HLS 导出的 IP 进行集成。
4、在 Jupyter Notebook 上完成 IP 的调用。

二、实验环境

1、PYNQ-Z2 远程实验室服务或物理板卡
2、Vitis HLS
3、Vivado

三、实验过程遇到的问题

【实验步骤】
1、依照 Lab1、Lab2 方式进行项目创建。
2、mul.h 文件中定义输入的 a,b 矩阵维度（32x32）和输出矩阵的维度(32x32)。
3、mul.cpp 文件中写明矩阵乘法的完整逻辑。
注：相关代码文件详见 Github。
4、给 mul.cpp 文件添加接口约束和循环流水如下：

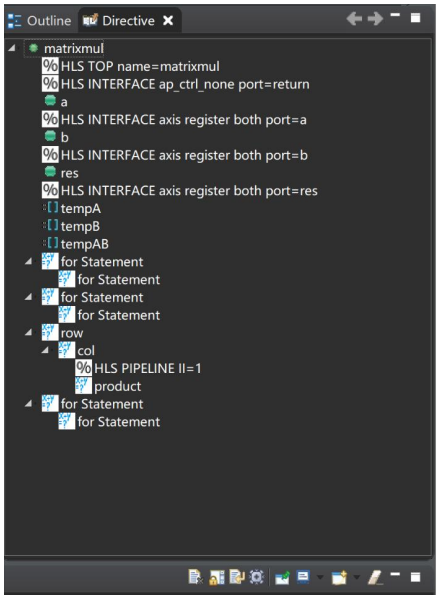

5、C simulation 结果

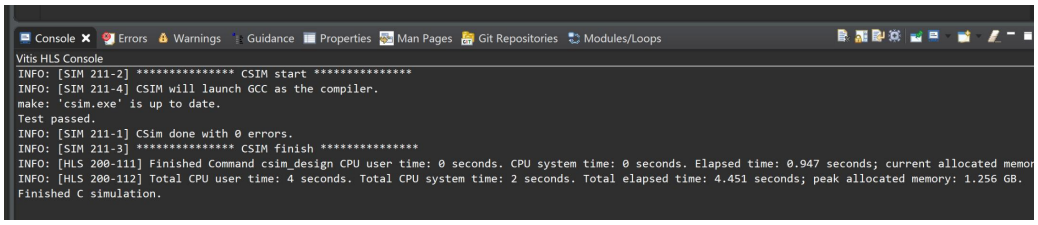

6、C synthesis 结果

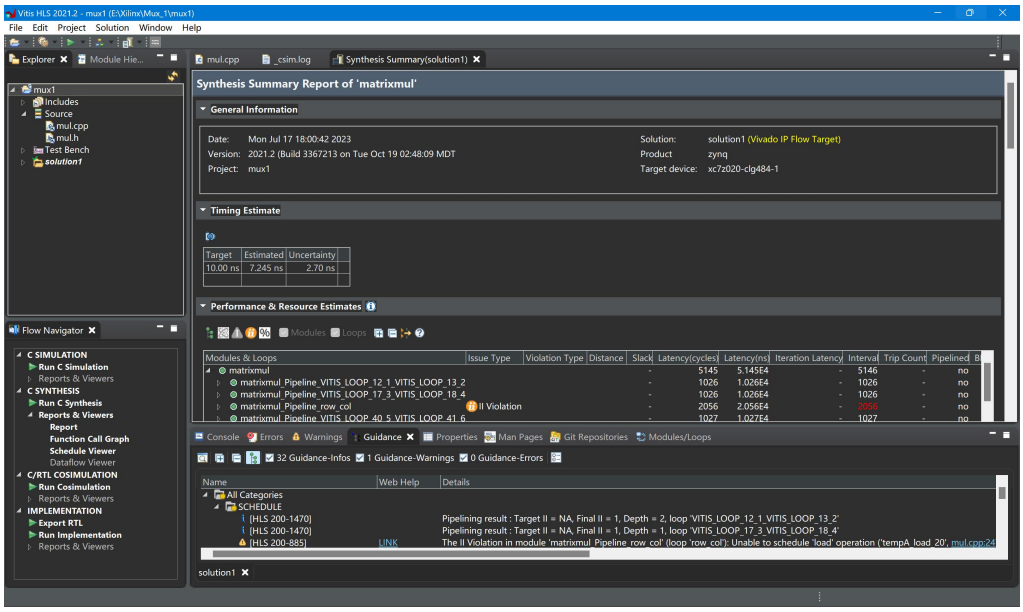

7、R/RTL Cosimulation

8、Export RTL 结果

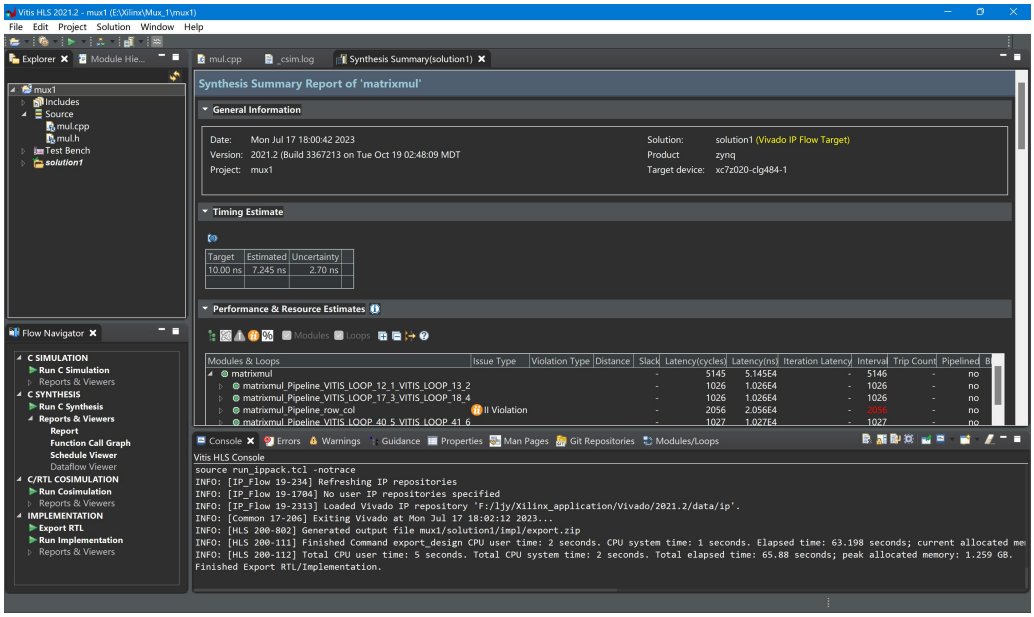

9、在 Vivado 中导入矩阵乘法 IP 核

10、进行 block design，添加 ZYNQ、HLS、DMA 的 IP。因在实验中设有两个两个 AXI 流数据的入口，一个 AXI 流数据的输出，所以要对 DMA 的读写端口数量进行修改，配置两个 DMA 的读端口，1 个 DMA 的写端口。

配置结果：DMA0：读端口、写端口；DMA1：读端口

11、最终完成的 block design 如下：

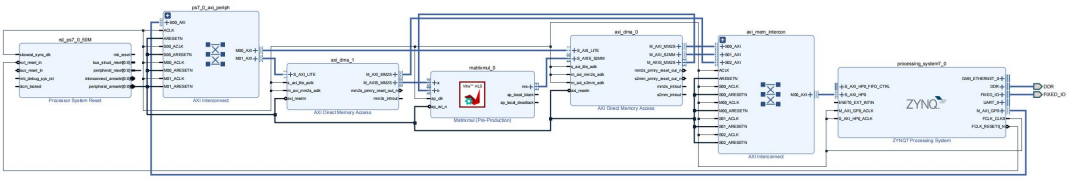

12、生成顶层调用文件、bit 文件。

13、在 jupyter notebook 中新建 ipynb 文件，Python 调用相关 IP 文件。设置 a、b、res 三个矩阵。其中 a 矩阵元素均为 6，b 矩阵元素均为 8。得到 res 矩阵结果如下：

注：完整代码参见 jupyter notebook。

```
In [2]: dma0.sendchannel.transfer(a)
        dma1.sendchannel.transfer(b)
        print("[a]=",a)
        print("[b]=",b)
```

```
[a]= [[6 6 6 ... 6 6 6]
 [6 6 6 ... 6 6 6]
 [6 6 6 ... 6 6 6]
 ...
 [6 6 6 ... 6 6 6]
 [6 6 6 ... 6 6 6]
 [6 6 6 ... 6 6 6]]
[b]= [[8 8 8 ... 8 8 8]
 [8 8 8 ... 8 8 8]
 [8 8 8 ... 8 8 8]
 ...
 [8 8 8 ... 8 8 8]
 [8 8 8 ... 8 8 8]
 [8 8 8 ... 8 8 8]]
```

```
In [3]: dma0.recvchannel.transfer(res)

        print("[res]=",res)
```

```
[res]= [[1536 1536 1536 ... 1536 1536 1536]
 [1536 1536 1536 ... 1536 1536 1536]
 [1536 1536 1536 ... 1536 1536 1536]
 ...
 [1536 1536 1536 ... 1536 1536 1536]
 [1536 1536 1536 ... 1536 1536 1536]
 [1536 1536 1536 ... 1536 1536 1536]]
```

【程序报错】

1、在分配内存的过程中，关于 allocate()的使用有误。

错例：

```
a = allocate(shape=(32,),dtype='u4')
b = allocate(shape=(32,), dtype='u4')
res = allocate(shape=(32,), dtype='u4')
```

错例输出：

```
print(res)
```

```
[0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0]
```

查询 allocate()相关文档如下：

Create a contiguous array of 5 32-bit unsigned integers

```
from pynq import allocate
input_buffer = allocate(shape=(5,), dtype='u4')
```

`device_address` property of the buffer

```
input_buffer.device_address
```

Writing data to the buffer:

```
input_buffer[:] = range(5)
```

Flushing the buffer to ensure the updated data is visible to the programmable logic:

```
input_buffer.flush()
```

随后修正如下：

a=allocate（shape=(32,32）,dtype='u4')

b=allocate（shape=(32,32）,dtype='u4')

res=allocate（shape=(32,32）,dtype='u4')

2、在调试数据数量过程中，res 矩阵总是仅输出 0。经单独调试如下代码后：

dma0.sendchannel.transfer(a)

dma1.sendchannel.transfer(b)

dma0.recvchannel.transfer(res)

确定是数据的传输出现问题。首先考虑到是否未能成功调用 IP 核。利用 mmol.ip_dict.keys()语句查找后，的确未找到矩阵乘法 IP 核。经继续查阅相关资料，得知调用过程中对矩阵大小的定义必须与 HLS 中 mul.h 的矩阵行列定义一致才能成功调用。调用失败的情况均是因为输入数据量过小（矩阵为 4x4）。经修改矩阵定义，并以循环嵌套结构进行正确赋值后，该问题解决。

四、实验收获与总结

1、对 Vitis HLS、Vivado 和 jupyter notebook 的使用有了更深入的了解。

2、在实验过程中完成了管脚约束，手动连线等操作，更好地掌握了新内容。

3、本实验是第一次接触 Python 编程，在遇到不懂的语法时，掌握了正确的查阅学习方法，高效地解决了遇到的问题。并锻炼了自己排查 bug 的能力。

4、与同学合作完成实验，在实验过程中相互学习和帮助，做到学以致用。